

MÁSTER UNIVERSITARIO EN TECNOLOGÍAS WEB, COMPUTACIÓN EN LA NUBE Y APLICACIONES MÓVILES

ASIGNATURA:

COMPUTACIÓN EN LA NUBE

5 DE JUNIO DE 2023

TRABAJO FINAL

Andoni Salcedo Navarro

1. Introducción

Este es un proyecto conjunto para las materias de Computación en la Nube, Desarrollo Basado en Componentes Distribuidos y Servicios, y Persistencia Relacional y No-Relacional de Datos. En el curso de Persistencia, se ha requerido establecer la capa de persistencia, tanto relacional como no relacional, basándose en ciertas especificaciones. Para el curso de DBCDS, se necesita diseñar e implementar servicios utilizando Spring Boot a través de una API REST que facilite el acceso a los datos. En cuanto a la materia de Computación en la Nube, se solicita que el despliegue se lleve a cabo utilizando contenedores que se ejecuten en Kubernetes. El diagrama 1 (también incluido en la entrega para mejorar la legibilidad) se muestra la arquitectura de despliegue de la aplicación en Kubernetes.

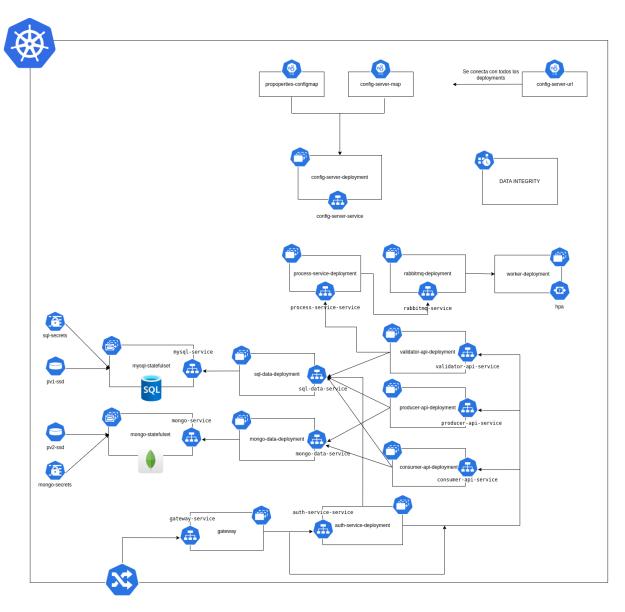


Figura 1: Diagrama de despliegue de la aplicación

En la entrega se expone que todos los recursos de yaml han de estar ubicados en el directorio **recursos**. Sin embargo, se ha decidido poner los recursos de los componentes dentro de cada componente de la aplicación, con la finalidad de automatizar el proceso de despliegue y construcción de imágenes. Para ello se ha utilizado el plug-in de maven que permite crear imágenes personalizadas para el proyecto dentro de maven. El resto de recursos se encuentran en la carpeta **RESOURCES/deploy/k8s**.

2. Recursos que se han utilizado

Se han utilizado los siguientes recursos para realizar el despliegue de la aplicación.

 Deployments: Es el recurso más utilizado para el despliegue se ha usado para la mayor parte de componentes, apis y servicios

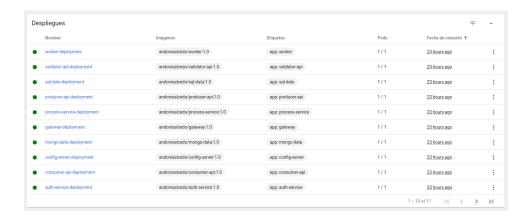


Figura 2: Deployments

 StatefulSets: Se ha empleado para el despliegue de las bases de datos de mongodb y mysql.



Figura 3: Statefulsets

 Ingress: Se ha utilizado como proxy para redirigir peticiones de fuera del clúster a dentro del cluster.



Figura 4: Ingress

ConfigMaps: Se ha utilizado para configurar la mayor parte de recursos de kubernetes. En primer lugar, se utiliza configmaps de tipo fichero para mostrarlo sobre el servidor de configuración este es el que guarda la configuración de todas las aplicaciones. Para ello, las aplicaciones han de tener la dirección de este servidor para cuando arranquen acceder a su configuración con lo que se ha creado otro configmap que define la url y las credenciales para acceder a este servidor. Por último, se ha creado otro configmap para configurar el propio servidor de configuración y configurarlo de tal manera que busque los ficheros de configuración en el directorio donde se ha montado los ficheros de configuración de todas las aplicaciones.



Figura 5: ConfigMaps

PersistentVolume: Se han creado dos volúmenes persistentes de la clase ssd, sirven para persistir los datos de las bases de datos estos volúmenes serán asociados a las bases de datos en los recursos de StatefulSets.



Figura 6: PersistentVolumes

 Secrets: Se han configurado dos secrets con las credenciales de acceso de usuario para las bases de datos.

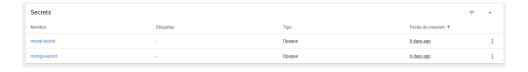


Figura 7: Secrets

- HPA: El Horizonal Pod Autoescaler se ha configurado para el componente worker por ello se ha limitado el uso de cpu de los workers para cuando este supere su capacidad cree un nuevo worker para manejar la carga.
- Services: Se han configurado la mayor parte de los servicios de kubernetes como servicios Headless, ya que no se requiere un acceso directo a los puertos desde fuera de kubernetes, pero si se necesita que el DNS configure su nombre para la resolución de la IP. Si se han configurado dos servicios de tipo nodeport con un puerto expuesto para las bases de datos, de esta manera se ha podido configurar la base de datos con herramientas como mysql workbench o mongodo compass.

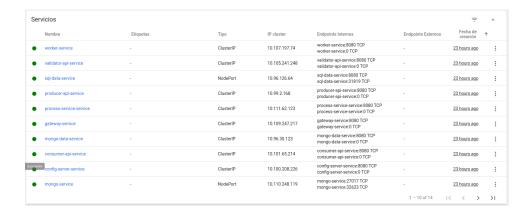


Figura 8: Services

■ CronJob: Como forma opcional se ha creado una aplicación es springboot que gestiona la consistencia de los datos entre ambas bases de datos, esta aplicación se debe ejecutar periódicamente consultando ambas bases de datos para comprobar que las entidades de una y los documentos de la otra coinciden, por ello se ha utilizado un cronjob que ejecuta cada 12 horas esta comprobación.



Figura 9: CronJob

Adicionalmente, se han configurado InitContainers, dado que la mayoria de recursos dependen de que el servidor de configuración este activo se ha decidido comprobar que este esta activo antes de arrancar la aplicación por ello se ha configurado todos los deployments de la siguiente forma:

Al iniciarse los componentes ocurriría lo siguiente:

```
        NAME
        READY
        STATUS
        RESTARTS
        AGE

        pod/auth-service-deployment-7785db5478-dtv55
        0/1
        Init:0/1
        0
        12s

        pod/config-server-deployment-578c57b964-z9t65
        1/1
        Running
        0
        11s

        pod/consumer-api-deployment-578c57b964-z9t65
        0/1
        Init:0/1
        0
        11s

        pod/gateway-deployment-5788f4768d-lcmzf
        0/1
        Init:0/1
        0
        10s

        pod/mongo-0
        1/1
        Running
        0
        12s

        pod/mongo-data-deployment-5bdf5b4c5-6mgb7
        0/1
        Init:0/1
        0
        9s

        pod/mysql-0
        0/1
        Terminating
        0
        67s

        pod/process-service-deployment-6c44b9bfc7-8jtrw
        0/1
        Init:0/1
        0
        8s

        pod/producer-api-deployment-6bcbf4ffd7-tk9kx
        1/1
        Running
        0
        12s

        pod/sql-data-deployment-6bcbf4ffd7-tk9kx
        1/1
        Running
        0
        12s

        pod/sql-data-deployment-6bcbf4ffd47-tk9kx
        1/1
        Running
        0
        12s

        pod/sql-data-deployment-6bbcbf4ffd47-tk9kx
        1/1
        Running
        0
```

Figura 10: InitContainer ejemplos

3. Pruebas

Para mostrar el funcionamiento del *Horizontal Pod Autoescaler* se va a someter al sistema a una alta carga de trabajo, para que la CPU de los workers límite y se tengan que crear más pods para gestionar las peticiones.

En una situación inicial el sistema se encontraría de la siguiente manera:

```
pod/validator-api-deployment-5c44475f8f-rgh2k 1/1 Running 0 71m
pod/worker-deployment-5bd88dc995-rzjjq 1/1 Running 0 71m
```

Figura 11: tras la ejecución de kubectl get all

```
validator-api-deployment-5c44475f8f-rgh2k 3m 153Mi
worker-deployment-5bd88dc995-rzjjq 2m 108Mi
```

Figura 12: tras la ejecución de kubectl top pod

Cuando se somete al sistema a altas cargas de trabajo el sistema se encontraría de la siguiente manera:

pody vactuator apt acptoyment services in a guzk	1/1	Kunn eng	0	7011
pod/worker-deployment-5bd88dc995-jh9gb	1/1	Running		30s
<pre>_pod/worker-deployment-5bd88dc995-rzjjq</pre>	1/1	Running		40m
pod/worker-deployment-5bd88dc995-w47qb	1/1	Running		30s

Figura 13: tras la ejecución de kubectl get all

worker-deployment-5bd88dc995-rzjjq 999m	
worker depeograms suddoddesss 12jjq	112Mi
worker-deployment-5bd88dc995-w47qb 593m	221Mi

Figura 14: tras la ejecución de kubectl top pod

De esta manera se muestra como los workers son capaces de adaptarse a la carga de trabajo si son sometidos a altas cargas de trabajo.